

UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

Facultad de Ciencias de la Computación — Carrera de Software

DESVIACIÓN METODOLÓGICA

Diseño de análisis del experimento humano-LLM

06\_Experimento/osf\_deviations.md

|                                     |                                       |
|-------------------------------------|---------------------------------------|
| Proyecto                            | SIMPA — Equipo AHMRV — ISR-401 — UTEQ |
| Responsable de esta declaración     | Denisses Huilcapi                     |
| Verificador                         | Allan Villafuerte                     |
| Fecha de registro de este documento | 11/09/2026                            |

1. Cambio declarado

|                     | Protocolo original (OSF, <a href="https://osf.io/4z35d/">https://osf.io/4z35d/</a> )                          | Diseño actualmente aplicable                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
|---------------------|---------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Diseño              | Cuasi-experimento con medidas apareadas y evaluación a ciegas (06_Experimento/protocolo.tex, línea 66)        | Grupos independientes, no apareados                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
| Análisis principal  | Prueba <i>t</i> apareada bilateral (o Wilcoxon con signo si no hay normalidad), corrección de Holm-Bonferroni | Modelo mixto de vínculo acumulativo para respuesta ordinal, un modelo por cada una de las cinco dimensiones: <code>puntuación_1-5 ~ origen + (1   evaluador) + (1   requisito)</code> , con <code>origen</code> como efecto fijo y <code>evaluador/requisito</code> como interceptos aleatorios cruzados. Enlace logístico de probabilidades proporcionales, salvo razón metodológica preespecificada para otro enlace. Implementación prevista: paquete <code>ordinal</code> de R (versión exacta a registrar en el momento de la ejecución) |
| Análisis de reserva | —                                                                                                             | Si el modelo mixto no converge: U de Mann-Whitney sobre la mediana por requisito entre evaluadoras, con $\delta$ de Cliff e IC 95 % como tamaño del efecto                                                                                                                                                                                                                                                                                                                                                                                    |

|                                 | Protocolo original (OSF, <a href="https://osf.io/4z35d/">https://osf.io/4z35d/</a> ) | Diseño actualmente aplicable                                                                                                                                                                                                                                                        |
|---------------------------------|--------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Acuerdo entre evaluadoras (RQ2) | $\kappa$ de Cohen (por pares) y $\kappa$ de Fleiss (conjunto)                        | $\alpha$ de Krippendorff con métrica ordinal como medida principal; $\kappa$ ponderado cuadrático por pares como medida secundaria. Se descarta $\kappa$ nominal de Cohen/Fleiss porque, en una escala ordinal de 1 a 5, penaliza igual un desacuerdo de un punto que uno de cuatro |

2. Motivo del cambio

El protocolo preregistrado prevé contrastes apareados sobre veinticinco pares. Al revisar el diseño antes de recoger puntuación alguna, se detectó que no existe correspondencia uno a uno entre cada requisito humano y uno generado por el LLM: ambos conjuntos proceden del mismo material fuente (ENTR-04), pero no describen necesariamente las mismas funciones, de modo que el emparejamiento carece de fundamento y el contraste apareado sería inválido. Construir esa correspondencia a mano introduciría un juicio subjetivo del propio equipo investigador, lo que comprometería la validez de constructo del estudio.

Por esa razón se declara la siguiente desviación, sometida como adenda prospectiva al registro **antes de recoger ninguna puntuación**:

1. Los dos conjuntos se tratan como grupos independientes, no apareados.
2. El análisis principal pasa a un modelo mixto ordinal (ver Sección 1), que respeta la naturaleza ordinal de la escala de cinco puntos y la estructura de evaluaciones repetidas (los mismos tres evaluadores puntúan ambos conjuntos) — algo que un contraste sobre medias no captura correctamente.
3. Como consecuencia directa del cambio de escala de análisis, el coeficiente de acuerdo entre evaluadoras también cambia: de  $\kappa$  nominal a  $\alpha$  de Krippendorff ordinal, por la misma razón de fondo (una métrica nominal no distingue la gravedad de un desacuerdo en una escala ordinal).

Ninguna de estas tres decisiones se tomará ni se revisará en función de los datos observados.

3. Fecha en que se detectó

El indicio más temprano verificable en el repositorio es el commit 2a5412b (“Incorporar manuscrito científico”), del **1 de septiembre de 2026, 16:54:14 (-05:00)**, autoría de Denisses Huilcapi — es el primer commit que incorpora este razonamiento por escrito, en la sección 6.1 del manuscrito. Si el equipo identificó el problema antes en una conversación no versionada, esa fecha anterior no cuenta con evidencia documental verificable, por lo que esta declaración usa el 1 de septiembre de 2026 como fecha de detección formal.

El protocolo original con diseño apareado se había cerrado y registrado públicamente en OSF apenas el día anterior (commit 8bc6bde, 31 de agosto de 2026, “Cerrar P8 con registro público OSF del protocolo experimental”). El experimento sigue sin ejecutarse a la fecha de este documento (06\_Experimento/readme.md: “Protocolo diseñado y registrado públicamente en OSF. Experimento no ejecutado.”), de modo que la desviación queda declarada con margen amplio respecto de cualquier recolección real de puntuaciones.

#### 4. Impacto en el análisis planeado

- **Prueba estadística original prevista:** prueba  $t$  apareada bilateral (o Wilcoxon de rangos con signo si no hay normalidad), con corrección de Holm-Bonferroni sobre los cinco valores  $p$  (`protocolo.tex`, sección de plan de análisis).
- **Prueba estadística ahora aplicable:** modelo mixto ordinal (Sección 1), con la prueba  $U$  de Mann-Whitney +  $\delta$  de Cliff como análisis de reserva si el modelo no converge.
- **Corrección por comparaciones múltiples:** se mantiene Holm-Bonferroni sobre los cinco contrastes del efecto de **origen**, uno por dimensión; se reportan valores  $p$  crudos y corregidos,  $\alpha = 0,05$ . Esto no cambia respecto del protocolo original.
- **Acuerdo entre evaluadoras:**  $\alpha$  de Krippendorff ordinal (principal) y  $\kappa$  ponderado cuadrático por pares (secundario), en vez de  $\kappa$  de Cohen/Fleiss nominal.

#### Potencia estadística — recalculada para el nuevo diseño

Con los mismos parámetros de referencia que fija el protocolo original ( $\alpha = 0,05$  bilateral, potencia objetivo  $1 - \beta = 0,80$ , tamaño de efecto medio  $d = 0,5$ ):

| Diseño                                                                           | Potencia con la muestra disponible         | Tamaño requerido para potencia 0,80                                                                 |
|----------------------------------------------------------------------------------|--------------------------------------------|-----------------------------------------------------------------------------------------------------|
| Apareado (protocolo original)                                                    | —                                          | $\approx 34$ pares (25 disponibles: in-suficiente — ya declarado en 07_Datos/desviaciones.md, D-01) |
| Grupos independientes (aproximación de sensibilidad, prueba $t$ de dos muestras) | $\approx 0,41$ con 25 requisitos por grupo | $\approx 64$ requisitos por grupo ( $\approx 128$ en total)                                         |

Este cálculo de sensibilidad ya está reportado en `manuscrito_final.tex`, sección 6.3, y se reproduce aquí como referencia cruzada. **No sustituye** una evaluación de potencia específica para el modelo mixto ordinal, que exigiría simulación con las distribuciones y componentes de varianza preespecificadas — algo que el propio manuscrito reconoce como pendiente.

**Conclusión de potencia:** el cambio de diseño agrava la limitación de potencia ya declarada para el diseño apareado, no la mantiene igual. Se reportará como amenaza a la validez de conclusión (Sección 7 del manuscrito), priorizando el tamaño del efecto con su intervalo de confianza al 95 % sobre la significación estadística. No se ampliará la muestra a posteriori para corregir esta limitación.

#### 5. Relación con el protocolo original pre-registrado en OSF

Este cambio se documenta como una **desviación**, no como una modificación retroactiva del protocolo original. El registro OSF público (<https://osf.io/4z35d/>) conserva intacta la versión del protocolo presentada al momento del registro; esta declaración se somete como adenda prospectiva, en la sección “Deviations from pre-registration” del registro, antes de recoger ninguna puntuación.

**Responsable de actualizar la plataforma OSF:** Allan Villafuerte (posee las credenciales de la cuenta del registro). Esta actualización en osf.io es una acción pendiente independiente de subir este archivo al repositorio — ambas deben quedar hechas antes de que EXP-06 avance a la sesión real de evaluación.

## 6. Limitación reconocida

El cambio de diseño de apareado a independiente reduce la potencia estadística alcanzable respecto del diseño original, tal como muestra la tabla de la Sección 4 (de  $\approx 34$  pares necesarios a  $\approx 64$  por grupo, con una potencia observable de apenas  $\approx 0,41$  con la muestra disponible). Esta limitación se reporta explícitamente en la sección de Amenazas a la Validez del manuscrito (categoría: validez de conclusión), siguiendo la misma práctica de transparencia ya aplicada en `07_Datos/desviaciones.md` (D-01 y D-02).