

UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

Facultad de Ciencias de la Computación — Carrera de Software

PROTOCOLO EXPERIMENTAL

Calidad de los requisitos funcionales elicitados por analistas humanos
frente a los generados por un modelo grande de lenguaje
a partir del mismo material fuente

Identificación	
Proyecto	SIMPA — Sistema Inteligente de Mantenimiento de Palma Africana
Equipo	AHMRV — Paralelo 4to “A”
Enfoque	Enfoque 1 de la Sección 5 de la guía de la Entrega 3 (2A)
Diseño	Cuasi-experimento con medidas apareadas y evaluación a ciegas
Registro OSF	Registro público retrospectivo respecto a la recolección del material fuente y anterior a la ejecución del experimento humano-LLM: https://osf.io/4z35d/ — véase osf_registration.pdf
Estado	Diseñado y registrado públicamente; el registro es posterior a la recolección del material fuente y anterior a la ejecución del experimento. Ejecución pendiente
Versión	1.2 — 7 de septiembre de 2026 (aclaración documental del alcance temporal del registro OSF)

1. Motivación y contexto

La revisión sistemática de Cheng *et al.* sobre inteligencia artificial generativa aplicada a la ingeniería de requisitos señala que la elicitación es una de las fases con menor evidencia empírica acumulada. Las guías de Vogelsang y Fischbach para el uso de modelos grandes de lenguaje en tareas de procesamiento de lenguaje natural aplicadas a requisitos proponen prácticas que aún no han sido validadas en contextos latinoamericanos ni en dominios agroindustriales.

Este estudio aporta un caso de evidencia adicional: compara el conjunto de requisitos funcionales elicitados por un equipo humano de estudiantes con el conjunto que produce un modelo grande de lenguaje a partir de la misma transcripción de entrevista, evaluados a ciegas por personas expertas independientes.

2. Pregunta de investigación en formato PICOC

Elemento	Definición para este estudio
Población	Requisitos funcionales de un sistema agroindustrial real de gestión y monitoreo de cultivo de palma africana
Intervención	Generación de requisitos funcionales mediante un modelo grande de lenguaje a partir de una transcripción de entrevista anonimizada

Elemento	Definición para este estudio
Comparación	Requisitos funcionales elicitados por el equipo humano a partir del mismo material fuente
Resultado	Puntuación en cinco dimensiones de calidad: completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente y consistencia interna
Contexto	Proyecto académico de ingeniería de requisitos, Ecuador, con evidencia de campo propia

Tabla 2: Marco PICOC del estudio

RQ1. ¿En qué dimensiones de calidad difieren los requisitos funcionales elicitados por un equipo humano de los generados por un modelo grande de lenguaje a partir del mismo material fuente?

RQ2. ¿Cuál es el grado de acuerdo entre personas evaluadoras independientes al valorar la calidad de requisitos funcionales sin conocer su procedencia?

3. Hipótesis

Para cada dimensión de calidad $d \in \{\text{completitud, ausencia de ambigüedad, verificabilidad, corrección, consistencia}\}$:

- $H_{0,d}$: no existe diferencia entre la puntuación media del conjunto humano y la del conjunto generado por el modelo. Formalmente, $\mu_{H,d} = \mu_{L,d}$.
- $H_{1,d}$: existe diferencia estadísticamente significativa. Formalmente, $\mu_{H,d} \neq \mu_{L,d}$.

La hipótesis alternativa se formula de forma **bilateral**. El equipo no anticipa la dirección del efecto: la literatura reporta resultados mixtos, y postular una dirección sin base sería un sesgo de expectativa.

4. Variables

Tipo	Variable	Operacionalización
Independiente	Origen del requisito	Nominal dicotómica: humano / modelo de lenguaje
Dependiente	Completitud	Ordinal 1–5: presencia de los ocho atributos de la plantilla
Dependiente	Ausencia de ambigüedad	Ordinal 1–5: unicidad de interpretación del enunciado
Dependiente	Verificabilidad	Ordinal 1–5: existencia de un criterio objetivamente comprobable
Dependiente	Corrección respecto de la fuente	Ordinal 1–5: fidelidad al contenido de la transcripción
Dependiente	Consistencia interna	Ordinal 1–5: ausencia de contradicción con otros requisitos del mismo conjunto
Control	Material fuente	Idéntico para ambos conjuntos: transcripción de ENTR-04
Control	Rúbrica de evaluación	Idéntica para ambos conjuntos
Control	Ceguera	Las personas evaluadoras desconocen la procedencia de cada requisito
Control	Orden de presentación	Aleatorizado para evitar efecto de posición

Tabla 3: Variables del estudio

5. Población, muestra y unidad de análisis

Unidad de análisis: el requisito funcional individual.

Conjunto	Tamaño	Procedencia
Conjunto A — generado por el modelo	≥ 25	Producido a partir de la transcripción anonimizada de ENTR-04
Conjunto B — elicitado por el equipo	≥ 25	Subconjunto del ERS trazado a EV-04 y evidencias relacionadas
Personas evaluadoras	3 (mínimo)	Estudiantes de otro paralelo de la misma asignatura, sin participación en el proyecto

Tabla 4: Conjuntos y participantes

Nota sobre el tamaño de las personas evaluadoras. Las guías del área recomiendan cinco personas evaluadoras. El equipo declara tres como mínimo viable y reportará el número efectivo. Si solo se alcanzan tres, se declarará como amenaza a la validez de conclusión.

6. Procedimiento

- Preparación del material fuente.** Se selecciona la transcripción completa de la entrevista ENTR-04 y se verifica su anonimización: sin nombres propios, sin cargos que identifiquen de forma unívoca y sin referencias reconocibles a la organización.
- Generación del conjunto A.** Se ejecuta el modelo con la consigna exacta:

“A partir del siguiente material fuente, redacta requisitos funcionales del sistema descrito, con los ocho atributos de la plantilla del sílabo.”

Se registran en `prompts_llm/`: consigna literal, modelo y versión exacta, temperatura, top-p, top-k, semilla, fecha y hora de la consulta, y respuesta completa sin edición.

- Preparación del conjunto B.** Se extraen del ERS los requisitos trazados a EV-04, presentados en el mismo formato que el conjunto A para impedir su identificación por la forma.
- Normalización de formato.** Ambos conjuntos se transcriben a una plantilla común: misma tipografía, misma estructura de campos, identificadores neutros del tipo R-001 a R-0NN. Se elimina toda marca que revele la procedencia.
- Aleatorización y ciego.** Los requisitos de ambos conjuntos se mezclan en orden aleatorio con semilla registrada. La correspondencia entre identificador neutro y procedencia se conserva en un archivo separado que las personas evaluadoras no reciben.
- Evaluación.** Cada persona evaluadora puntúa cada requisito de 1 a 5 en las cinco dimensiones, de forma independiente y sin comunicación con las demás.
- Análisis.** Se aplica el plan de la Sección 8.
- Desciego y discusión.** Se revela la procedencia y se analizan los desacuerdos entre personas evaluadoras y los casos extremos.

7. Instrumentos

Instrumento	Descripción	Ubicación
Material fuente	Transcripción anonimizada de ENTR-04	02_Evidencias/Transcripciones/
Consigna	Texto literal, parámetros del modelo y respuesta	06_Experimento/prompts_llm/
Rúbrica	Cinco dimensiones, escala 1–5, con descriptor por nivel	06_Experimento/instrumentos/
Hoja de puntuación	Una por persona evaluadora, en formato tabular	06_Experimento/instrumentos/
Consentimiento	Formulario para las personas evaluadoras	06_Experimento/instrumentos/

Tabla 5: Instrumentos del estudio

Descriptores de la rúbrica. Cada dimensión se puntúa según la escala siguiente, común a las cinco: 1, la propiedad está ausente; 2, presente de forma marginal; 3, presente con deficiencias apreciables; 4, presente con deficiencias menores; 5, plenamente presente. Cada nivel se acompaña de un ejemplo positivo y uno negativo en el documento de la rúbrica, con el fin de reducir la variabilidad de criterio entre personas evaluadoras.

8. Plan de análisis estadístico

El plan se fija *antes* de disponer de los datos producidos por el experimento humano–LLM. El material fuente de entrevistas ya existía al momento del registro. No se modificará en función de los resultados experimentales obtenidos.

1. **Estadística descriptiva.** Media, mediana, desviación típica y rango intercuartílico por conjunto y por dimensión.
2. **Prueba de normalidad.** Shapiro–Wilk sobre las diferencias apareadas de cada dimensión, con $\alpha = 0,05$.
3. **Prueba de hipótesis.** Si las diferencias siguen distribución normal, prueba t para muestras apareadas. En caso contrario, prueba de los rangos con signo de Wilcoxon. Contraste bilateral, $\alpha = 0,05$.
4. **Corrección por comparaciones múltiples.** Se contrastan cinco dimensiones sobre el mismo conjunto de datos. Se aplica corrección de Holm–Bonferroni sobre los cinco valores p obtenidos. Se reportan tanto los valores crudos como los corregidos.
5. **Tamaño del efecto.** Cohen d para muestras apareadas cuando se aplique la prueba paramétrica; Cliff δ cuando se aplique la no paramétrica. Se reporta con su intervalo de confianza al 95%.
6. **Acuerdo entre personas evaluadoras.** Coeficiente κ de Cohen para cada par de personas evaluadoras y κ de Fleiss para el conjunto completo. Se interpreta según los umbrales convencionales del área.
7. **Potencia estadística.** Cálculo previo fijando $\alpha = 0,05$, potencia $1 - \beta = 0,80$ y tamaño de efecto medio $d = 0,5$. Con esos parámetros, el tamaño muestral requerido para una prueba t apareada bilateral es de aproximadamente 34 pares. **El diseño contempla 25 pares,**

lo que sitúa la potencia alcanzable por debajo del objetivo. Esta limitación se declara de forma expresa y se reporta como amenaza a la validez de conclusión; no se incrementará artificialmente el tamaño muestral duplicando requisitos.

Todas las tablas y figuras del informe de resultados se producirán mediante los scripts versionados en 06_Experimento/scripts_analisis/. No se aceptarán cifras calculadas manualmente.

9. Amenazas a la validez previstas

Categoría	Amenaza	Mitigación prevista
Constructo	La rúbrica de cinco dimensiones puede no capturar la calidad de un requisito en su totalidad	Las dimensiones proceden de la literatura del área y de los criterios transversales de la propia guía; se declara la limitación
Interna	El conjunto humano fue elaborado por el mismo equipo que ejecuta el estudio	Evaluación a ciegas, normalización de formato e identificadores neutros
Interna	Efecto de posición en el orden de presentación	Aleatorización con semilla registrada
Externa	Un único material fuente, un único dominio y un único modelo de lenguaje	Se declara. No se generalizará más allá del caso estudiado
Externa	Las personas evaluadoras son estudiantes, no profesionales en ejercicio	Se declara el perfil real; no se atribuirá al juicio la condición de experto profesional
Conclusión	Potencia estadística por debajo de 0,80 con 25 pares	Se declara antes de ejecutar; se reporta el intervalo de confianza del tamaño del efecto y no solo el valor p
Conclusión	Acuerdo bajo entre personas evaluadoras	Se reporta κ con independencia de su valor; si resulta bajo, se discute como hallazgo y no se descarta

Tabla 6: Amenazas a la validez identificadas antes de la ejecución

10. Consideraciones éticas

Las personas evaluadoras firman un consentimiento específico que declara el propósito del estudio, el carácter voluntario de su participación, la ausencia de compensación y el uso académico de sus puntuaciones de forma agregada y anónima.

El material fuente sometido al modelo de lenguaje está anonimizado: no contiene nombres propios, cargos identificativos ni referencias reconocibles a la organización. La persona participante ENTR-04 autorizó de forma expresa el uso de sus datos anonimizados en publicaciones científicas revisadas por pares, conforme a la adenda ética de la segunda ronda.

Ninguna puntuación individual se publicará de forma atribuible a una persona evaluadora concreta.

11. Compromiso de reporte íntegro

El equipo se compromete de forma expresa a:

1. Reportar el resultado obtenido con independencia de si confirma o refuta la hipótesis nula.
2. No modificar el plan de análisis en función de los datos observados.

3. Publicar los datos crudos de puntuación junto con los scripts que producen cada tabla.
4. Declarar el número efectivo de personas evaluadoras y de requisitos evaluados.
5. No redactar las secciones de resultados ni de discusión antes de disponer de datos analizados.

Estado a la fecha de este documento. El protocolo se encuentra **diseñado y registrado públicamente en OSF** (<https://osf.io/4z35d/>); el experimento **no ha sido ejecutado**. En consecuencia, el ERS/SRS de la Entrega 3 (2A) no contiene sección de resultados ni de discusión de este estudio. Ambas corresponden a la Entrega 4 (2B), una vez recogidos y analizados los datos primarios.

Nota de versión y alcance temporal. La versión 1.2 conserva la URL y el estado administrativo del registro público OSF y explicita su relación temporal con el material fuente. El registro es retrospectivo respecto a la recolección de entrevistas, pero anterior a la ejecución del experimento comparativo humano–LLM. Por ello no se presenta como prerregistro del proyecto completo ni de la recolección ya realizada. Esta aclaración no modifica la pregunta de investigación, las hipótesis, las variables, la muestra, el procedimiento ni el plan de análisis del experimento.

Villafuerte Rosero Allan Noe

Analista líder — Equipo AHMRV

Ing. Gleiston Cicerón Guerrero Ulloa,
PhD

Docente responsable — ISR-401

Quevedo, 3 de agosto de 2026.