

Calidad de requisitos funcionales: humanos frente a un modelo grande de lenguaje. Estudio comparativo registrado

Allan N. Villafuerte Rosero, Denisses F. Huilcapi León, Edson N. Rizzo Vélez,
Josthyn E. Macías Herrera, Francisco J. Arboleda Yanza, and Anderson A.
Alcívar Vélez

Universidad Técnica Estatal de Quevedo, Facultad de Ciencias de la Computación,
Quevedo, Ecuador

Resumen Contexto y motivación. Los modelos grandes de lenguaje se incorporan con rapidez a la elicitación de requisitos, pero la evidencia empírica sobre la calidad de los requisitos que producen sigue siendo limitada, especialmente en dominios agroindustriales y en contextos latinoamericanos.

Pregunta o problema. ¿Difiere la calidad de los requisitos funcionales elicitados por un equipo humano de la de los generados por un modelo grande de lenguaje a partir del mismo material fuente, y con qué grado de acuerdo la valoran personas evaluadoras que desconocen su procedencia?

Método y resultados. Se ejecutó un estudio comparativo con evaluación a ciegas sobre un caso real de ingeniería de requisitos en una unidad productiva de palma africana. Se evaluaron 25 requisitos humanos y 25 generados por un modelo de lenguaje, puntuados por tres personas evaluadoras en cinco dimensiones de calidad, para un total de 750 puntuaciones ordinales. El análisis principal empleó modelos ordinales mixtos con origen como efecto fijo y evaluador y requisito como interceptos aleatorios. No se encontraron diferencias estadísticamente significativas entre los requisitos humanos y los generados por el modelo en ninguna dimensión después de aplicar la corrección de Holm. Los odds ratios para LLM frente a Humano se situaron entre 0,739 y 0,766. El acuerdo interevaluador fue muy bajo: el α de Krippendorff ordinal osciló entre $-0,015$ y $0,027$.

Contribución y limitaciones. Los resultados aportan evidencia empírica sobre el uso de modelos de lenguaje en elicitación de requisitos en un dominio agroindustrial. La ausencia de diferencias significativas no se interpreta como equivalencia entre ambos orígenes, debido al tamaño muestral, la potencia limitada, el bajo acuerdo entre evaluadores y el uso de un único material fuente y un único modelo.

Palabras clave Ingeniería de requisitos · Modelos grandes de lenguaje · Calidad de requisitos · Estudio comparativo registrado · Evaluación a ciegas.

1. Introducción y motivación

La elicitación de requisitos incide de forma persistente en el resultado de los proyectos de software [?], y los atributos de calidad se definen de forma heterogénea entre estudios [?]. Sobre ese terreno se han incorporado con rapidez los modelos grandes de lenguaje: la elicitación es una de las fases con menor evidencia acumulada [?], valorar la calidad del artefacto generado exige un procedimiento de evaluación controlado [?], y las prácticas de uso propuestas aún no han sido validadas de forma independiente [?].

Este trabajo presenta los resultados de un estudio comparativo con evaluación a ciegas, registrado antes de recoger las puntuaciones experimentales, en un contexto poco representado: un proyecto de ingeniería de requisitos sobre una unidad productiva agroindustrial real en Ecuador. El estudio compara requisitos funcionales elicitados por el equipo humano con requisitos generados por un modelo grande de lenguaje a partir del mismo material fuente.

2. Trabajo relacionado

La revisión que sustenta este diseño es **dirigida y de carácter narrativo**, no una revisión sistemática: no se conservó un registro auditable de consultas, y por tanto no se reclama exhaustividad ni reproducibilidad de la búsqueda.

Calidad de requisitos. La ISO/IEC/IEEE 29148:2018 fija los atributos exigibles a un requisito y a un conjunto [?] y es el marco normativo de este estudio; Pohl [?] y Wiegers y Beatty [?] los desarrollan en términos operativos. La dispersión de definiciones entre estudios [?] motiva que aquí se declare la operacionalización de cada dimensión (Sección 5). Ferrari et al. mostraron que la ambigüedad y el conocimiento tácito en entrevistas producen omisiones que el analista no detecta [?], hallazgo pertinente porque el material fuente de ambos conjuntos es una transcripción de entrevista. La línea sobre explicabilidad como requisito no funcional [?] enmarca los componentes de inteligencia artificial del sistema objeto del proyecto.

Contexto agroindustrial. La producción reciente sobre palma africana se concentra en el componente de percepción [?,?] y no aborda la especificación de requisitos del sistema que la incorpora, que es el hueco al que responde el proyecto en el que se inserta este estudio.

Método. El diseño sigue las guías de Wohlin et al. [?] y el reporte la plantilla de Jedlitschka et al. [?]. La práctica de prerregistro se apoya en Nosek et al. [?].

3. Contexto del estudio

El estudio se inserta en un proyecto de ingeniería de requisitos para un sistema de gestión del mantenimiento de un cultivo de palma africana, en una unidad productiva de unas cien hectáreas en la costa ecuatoriana, designada con un seudónimo por acuerdo de confidencialidad.

La especificación se elaboró conforme a la ISO/IEC/IEEE 29148:2018 [?], con los atributos de la ISO/IEC 25010:2023 [?] como marco de los requisitos no funcionales. El catálogo, sometido a inspección formal y a control de cambios, comprende **42 requisitos funcionales, 19 no funcionales, 10 restricciones de diseño y 8 requisitos legales**. La evidencia de campo procede de entrevistas semiestructuradas, un cuestionario al personal operativo, documentación interna y observación directa, bajo consentimiento informado y seudonimizada conforme a la legislación ecuatoriana [?]. El experimento utiliza únicamente la transcripción anonimizada de una entrevista como material fuente común a los dos conjuntos.

4. Preguntas de investigación

Marco PICOC: **población**, requisitos funcionales de un sistema agroindustrial real; **intervención**, su generación mediante un modelo grande de lenguaje desde una transcripción anonimizada; **comparación**, los elicitados por el equipo humano desde el mismo material; **resultado**, la puntuación en cinco dimensiones de calidad; **contexto**, un proyecto académico de ingeniería de requisitos en Ecuador.

RQ1. ¿En qué dimensiones de calidad difieren los requisitos funcionales elicitados por un equipo humano de los generados por un modelo grande de lenguaje a partir del mismo material fuente?

RQ2. ¿Cuál es el grado de acuerdo entre personas evaluadoras independientes al valorar la calidad de requisitos funcionales sin conocer su procedencia?

Para cada dimensión d , la hipótesis nula sostiene que la distribución de puntuaciones no difiere entre conjuntos. El contraste es **bilateral**: la literatura reporta resultados mixtos y postular una dirección sin base constituiría un sesgo de expectativa.

5. Diseño del estudio

5.1. Variables

La **variable independiente** es el origen del requisito, nominal dicotómica. Las **variables dependientes** son cinco puntuaciones ordinales de 1 a 5, con descriptores por nivel y un ejemplo positivo y otro negativo en cada uno: *completitud* (presencia de los atributos de la plantilla), *ausencia de ambigüedad* (unicidad de interpretación), *verificabilidad* (existencia de un criterio objetivamente comprobable), *corrección* (fidelidad al contenido de la transcripción) y *consistencia interna* (ausencia de contradicción con el resto del conjunto). Se controlan el material fuente y la rúbrica, idénticos para ambos conjuntos; la ceguera de las personas evaluadoras respecto del origen; y el orden de presentación, aleatorizado con semilla registrada.

5.2. Materiales y participantes

Ambos conjuntos comprendieron veinticinco requisitos; el humano se extrajo del catálogo seleccionando los trazados a la evidencia de la entrevista fuente. Participaron tres personas evaluadoras independientes, estudiantes de otro paralelo de la misma asignatura sin participación en el proyecto. Las tres evaluaron los 50 requisitos en las cinco dimensiones previstas, generando 750 puntuaciones ordinales. El número reducido de evaluadores constituye una limitación del estudio.

5.3. Procedimiento

Verificada la anonimización de la transcripción fuente, el conjunto generado se obtiene con una consigna literal única, registrando modelo y versión, temperatura, *top-p*, *top-k*, semilla, fecha y hora, y la respuesta sin edición [?]. Ambos conjuntos se transcriben a una plantilla común con identificadores neutros, sin marca de procedencia, y se mezclan en orden aleatorio con semilla registrada; la correspondencia entre identificador y origen se conserva aparte y no se entrega a las evaluadoras. Cada una puntúa todos los requisitos de forma independiente. La procedencia se revela solo al completarse la recolección.

6. Plan de análisis

Ejecución del análisis. El análisis se ejecutó después de completar la recolección de las puntuaciones. Las decisiones metodológicas principales utilizadas en esta etapa fueron fijadas antes de observar dichas puntuaciones y quedaron documentadas en el repositorio. El protocolo público original no se modificó retroactivamente; las diferencias respecto de aquel protocolo se conservan como desviaciones declaradas.

6.1. Desviación respecto del plan original

El protocolo original preveía contrastes **apareados** sobre unos veinticinco pares. Antes de recoger las puntuaciones se constató que no existía una correspondencia uno a uno metodológicamente justificable entre cada requisito humano y uno generado por el modelo: ambos conjuntos proceden del mismo material fuente, pero no describen necesariamente las mismas funciones. Por ello, un contraste apareado habría impuesto una estructura inexistente.

La desviación quedó documentada en el repositorio antes de recoger las puntuaciones experimentales y consistió en:

1. tratar los dos conjuntos como **grupos independientes**, no apareados;
2. utilizar como análisis principal un **modelo mixto de vínculo acumulativo** para respuesta ordinal [?], con un modelo independiente para cada una de las cinco dimensiones y la especificación

$$\text{puntuación}_{1-5} \sim \text{origen} + (1 \mid \text{evaluador}) + (1 \mid \text{requisito});$$

3. utilizar origen como efecto fijo y evaluador y requisito como interceptos aleatorios cruzados, con enlace logístico de probabilidades proporcionales;
4. reservar la prueba U de Mann–Whitney sobre la mediana por requisito, acompañada de δ de Cliff e intervalo de confianza al 95 % [?], exclusivamente para el caso de que el modelo principal no convergiera.

Los cinco modelos principales convergieron sin advertencias, por lo que no fue necesario ejecutar el análisis de reserva. La implementación se realizó con el paquete `ordinal` de R, versión 2026.7.26.

6.2. Contrastes y acuerdo entre evaluadores

Se aplicó la corrección secuencial de Holm [?] sobre los cinco contrastes del efecto de origen, uno por dimensión, con $\alpha = 0,05$. Se reportan tanto los valores p crudos como los corregidos.

Para RQ2 se utilizó el α de Krippendorff con métrica ordinal [?] como medida principal de acuerdo y el κ de Cohen ponderado cuadráticamente [?] por pares como medida secundaria.

6.3. Potencia

Como aproximación de sensibilidad, y no como potencia específica del modelo ordinal, se había calculado previamente la potencia de un contraste convencional de dos grupos independientes con $\alpha = 0,05$ bilateral y $d = 0,5$. Veinticinco requisitos por grupo proporcionan una potencia aproximada de **0,41**; alcanzar 0,80 requeriría aproximadamente 64 requisitos por grupo.

Esta limitación se mantuvo durante la ejecución y la muestra no se amplió después de observar los resultados. Por ello, la interpretación considera conjuntamente los estimadores, sus intervalos de confianza y los valores p , sin equiparar ausencia de significación con equivalencia.

Todas las cifras que se presentan a continuación proceden de scripts versionados en el repositorio.

7. Resultados

El experimento incluyó 25 requisitos del conjunto humano y 25 requisitos generados por el modelo. Tres evaluadores puntuaron los 50 requisitos en cinco dimensiones, produciendo un total de 750 puntuaciones ordinales.

7.1. RQ1: comparación entre requisitos humanos y generados por LLM

Descriptivamente, las medias del conjunto humano fueron ligeramente superiores en las cinco dimensiones. Para completitud y ausencia de ambigüedad la media fue 4,36 en humanos frente a 4,25 en LLM; para verificabilidad, 4,35

frente a 4,24; para corrección, 4,37 frente a 4,25; y para consistencia, 4,36 frente a 4,25. La mediana fue 4 y el rango intercuartil 1 en ambos orígenes y en todas las dimensiones.

La Tabla 1 presenta el efecto de origen estimado por los modelos ordinales mixtos. Humano se utilizó como categoría de referencia; por tanto, un *odds ratio* menor que 1 representa un desplazamiento estimado hacia puntuaciones menores para LLM.

Cuadro 1. Efecto de origen LLM frente a Humano en los modelos ordinales mixtos.

Dim.	β	OR	IC 95 %	OR	p	p_{Holm}
COM	-0,267	0,766	[0,416; 1,411]	0,392	1,000	
AMB	-0,283	0,754	[0,394; 1,442]	0,393	1,000	
VER	-0,281	0,755	[0,385; 1,481]	0,414	1,000	
COR	-0,303	0,739	[0,393; 1,390]	0,348	1,000	
CON	-0,267	0,766	[0,416; 1,411]	0,392	1,000	

Los cinco coeficientes fueron negativos y los cinco *odds ratios* inferiores a 1. Sin embargo, todos los intervalos de confianza incluyeron 1 y ninguno de los contrastes alcanzó significación estadística. Tras la corrección de Holm, los cinco valores p ajustados fueron 1,000.

Por tanto, en esta muestra **no se encontró evidencia estadísticamente significativa de diferencias de calidad entre los requisitos humanos y los generados por el LLM en ninguna de las cinco dimensiones**. Este resultado no demuestra equivalencia entre ambos orígenes.

Complejidad y consistencia produjeron estimaciones idénticas porque las puntuaciones observadas para ambas dimensiones fueron idénticas en el conjunto analizado.

7.2. RQ2: acuerdo entre evaluadores

El acuerdo entre los tres evaluadores fue bajo en todas las dimensiones. La Tabla 2 muestra el α de Krippendorff con métrica ordinal.

Cuadro 2. Acuerdo interevaluador mediante α de Krippendorff ordinal.

Dimensión	α de Krippendorff
COM	-0,015
AMB	-0,003
VER	0,027
COR	-0,003
CON	-0,015

Los valores se situaron aproximadamente entre $-0,015$ y $0,027$, es decir, muy próximos a cero. Como medida secundaria, los valores de κ ponderado cuadrático por pares oscilaron entre aproximadamente $-0,044$ y $0,297$.

En conjunto, RQ2 muestra que las personas evaluadoras presentaron un **grado de acuerdo muy bajo** al aplicar la rúbrica a los requisitos cegados.

8. Discusión

Los resultados de RQ1 muestran una dirección consistente: las puntuaciones estimadas favorecieron ligeramente al conjunto humano en las cinco dimensiones. No obstante, la magnitud de la incertidumbre es suficiente para que todos los intervalos de confianza de los *odds ratios* incluyan 1. Con la muestra disponible no es posible sostener que exista una diferencia estadísticamente detectable entre los dos orígenes.

Este resultado debe distinguirse de una demostración de igualdad o equivalencia. El estudio posee potencia limitada y fue diseñado como una comparación exploratoria en un único caso. La ausencia de significación puede ser compatible tanto con diferencias pequeñas como con una muestra insuficiente para detectarlas con precisión.

Desde una perspectiva aplicada, los requisitos producidos por el modelo obtuvieron puntuaciones descriptivas cercanas a las del conjunto humano. Esto sugiere que un modelo grande de lenguaje puede producir artefactos que, bajo determinadas condiciones, reciban valoraciones de calidad similares. Sin embargo, los datos no respaldan afirmar que el modelo pueda sustituir al proceso humano de elicitación: el estudio evalúa un único material fuente, un único modelo y un único dominio.

El resultado de RQ2 es especialmente importante para interpretar RQ1. El acuerdo interevaluador fue muy bajo en todas las dimensiones, lo que indica una variabilidad considerable en la aplicación de la rúbrica. Aunque los modelos mixtos incorporaron al evaluador como efecto aleatorio, esta falta de concordancia reduce la precisión con la que puede caracterizarse la calidad de cada requisito y debe considerarse una amenaza a la validez de medición y de conclusión.

En consecuencia, la principal aportación empírica del estudio no es demostrar superioridad de uno de los dos orígenes, sino documentar que, bajo este diseño, no se detectaron diferencias significativas y que la variabilidad entre evaluadores constituye un componente relevante del problema de medición. Estudios posteriores deberían ampliar el número de materiales fuente, modelos, dominios y evaluadores, además de estudiar estrategias para aumentar la consistencia en la aplicación de la rúbrica.

9. Amenazas a la validez

Se identificaron antes de la ejecución, según las categorías de Wohlin et al. [?].

Constructo. La rúbrica puede no capturar la calidad de un requisito en su totalidad; las dimensiones proceden de la literatura [?,?] y la limitación se declara. La escala ordinal comprime juicios heterogéneos, lo que se mitiga con descriptores y ejemplos por nivel.

Interna. El conjunto humano lo elaboró el mismo equipo que ejecuta el estudio; se mitiga con evaluación a ciegas, identificadores neutros y orden aleatorizado con semilla registrada.

Externa. Un único material fuente, dominio y modelo; no se generalizará más allá del caso. Las evaluadoras son estudiantes y no profesionales: se declara el perfil real y no se atribuirá a su juicio la condición de experto.

Conclusión. La potencia queda por debajo de 0,80, por lo que se reporta el tamaño del efecto con intervalo de confianza y no solo el valor p . Un acuerdo bajo entre evaluadoras se reportará igualmente y se discutirá como hallazgo. El cambio de diseño apareado a grupos independientes que agraba esta limitación de potencia se declara como desviación prospectiva en `06_Experimento/osf_deviations.md`.

Amenazas del componente cualitativo que provee el material fuente. La transcripción que actúa como material fuente y el catálogo de requisitos del que se extrae el conjunto humano proceden de un estudio de campo previo, cuya interpretación se contrastó con las personas participantes mediante *member-checking*. Dos casos de ese proceso afectan a la confianza en dicho material y se declaran aquí; ambos constan en el registro de correcciones del proyecto (`correcciones_aplicadas.md`, casos D-02 y D-06).

Instrumento. Un enunciado de validación empleó el término *herramienta*, que una de las tres personas consultadas interpretó como herramienta física de trabajo y no como aplicación informática. El defecto es de formulación y no de la persona participante, y redujo de tres a dos las posiciones obtenibles sobre ese enunciado. Se reformuló el enunciado, se declara la pérdida de una posición y no se recabó de nuevo por encontrarse cerrado el trabajo de campo.

Credibilidad. Un segundo enunciado recibió posiciones incompatibles: dos personas confirmaron una carencia de detalle en los reportes que una tercera negó, sin que exista evidencia documental independiente que permita adjudicar entre ambas lecturas. La interpretación se conservó por contar con el respaldo de dos de tres fuentes y la divergencia se reporta sin conciliar, lo que limita la confianza en la parte del material derivada de ese enunciado.

10. Estado y contribución

El protocolo experimental fue registrado públicamente antes de la ejecución del experimento humano-LLM y antes de recoger sus puntuaciones. El material fuente de entrevistas, en cambio, ya existía en ese momento; por ello, el registro no se presenta como prerregistro del trabajo de campo previo ni del proyecto completo.

El experimento comparativo se encuentra **ejecutado y analizado**. Se evaluaron 25 requisitos humanos y 25 requisitos generados por el modelo mediante

tres evaluadores independientes y una rúbrica de cinco dimensiones. Los resultados se reportan con independencia de que los contrastes hayan resultado significativos.

La contribución es doble: por una parte, aporta evidencia empírica sobre la calidad percibida de requisitos funcionales humanos y generados por un modelo grande de lenguaje en un dominio agroindustrial; por otra, documenta un procedimiento reproducible de cegado, evaluación ordinal y análisis del acuerdo entre evaluadores.

El registro público no equivale a un *Registered Report* con aceptación en fase 1, puesto que el diseño no fue sometido a revisión editorial previa. Las desviaciones respecto del plan original se documentan explícitamente y el protocolo registrado no se modifica retroactivamente.

Declaración de disponibilidad de datos

El registro del protocolo está disponible en Open Science Framework (<https://osf.io/4z35d/>). El repositorio público del proyecto se encuentra en https://github.com/AlanNVR/SIMPA_ISR401.

Como material complementario del proyecto se mantiene un depósito con estadística descriptiva agregada del cuestionario aplicado al personal operativo (10.5281/zenodo.22236500). Dicho depósito corresponde a un componente previo del proyecto y no constituye el depósito de los datos experimentales humano-LLM.

El repositorio del proyecto contiene los artefactos versionados utilizados para el experimento, incluidos los conjuntos cegados y procesados, los scripts de preparación y análisis y los resultados estadísticos reportados en este manuscrito. La correspondencia confidencial utilizada durante el cegado se mantuvo separada del repositorio público durante la evaluación.

Las personas evaluadoras se identifican mediante códigos y no por sus nombres en los datos analíticos. La gestión y publicación de sus datos debe mantenerse de acuerdo con el consentimiento aplicable y con las medidas de privacidad documentadas en el proyecto. La organización de los artefactos sigue los principios FAIR [?].

Uso de tecnologías asistidas por inteligencia artificial

Como objeto de estudio. Uno de los conjuntos experimentales fue generado mediante un modelo grande de lenguaje a partir del material fuente definido para el experimento. La consigna, los parámetros disponibles de ejecución y los artefactos resultantes se documentaron dentro del flujo experimental.

Como apoyo al trabajo académico. Durante la preparación y revisión del manuscrito se utilizaron asistentes de inteligencia artificial, incluidos Claude (Anthropic) y ChatGPT (OpenAI), como apoyo para redacción, reestructuración, revisión de coherencia y formulación de interpretaciones.

Los asistentes no sustituyeron la ejecución del análisis estadístico. Las cifras, estimadores, intervalos de confianza, valores p y medidas de acuerdo reportados proceden de los datos reales y de los scripts versionados del proyecto. Las personas autoras revisaron las interpretaciones propuestas y mantienen la responsabilidad sobre las decisiones metodológicas, la verificación de los resultados y las afirmaciones finales del manuscrito.

Las referencias bibliográficas deben ser contrastadas con sus fuentes bibliográficas o editoriales originales y con sus identificadores persistentes cuando estén disponibles antes de una eventual presentación externa.

Agradecimientos y conflicto de intereses

Las personas autoras agradecen a la unidad productiva participante y a su personal el tiempo dedicado a las entrevistas y el acceso a la documentación operativa. Agradecemos asimismo al docente supervisor del proyecto por la orientación académica y metodológica durante el desarrollo del estudio. Una de las personas autoras mantiene una relación de parentesco con el representante de la organización participante; la circunstancia se declaró ante la instancia académica antes del trabajo de campo y se adoptaron medidas de mitigación documentadas. No se declaran otros conflictos de intereses.

Referencias