

Calidad de requisitos funcionales: humanos frente a un modelo grande de lenguaje. Estudio prerregistrado

Allan N. Villafuerte Rosero, Denisses F. Huilcapi León, Edson N. Rizzo Vélez,
Josthyn E. Macías Herrera, Francisco J. Arboleda Yanza, and Anderson A.
Alcívar Vélez

Universidad Técnica Estatal de Quevedo, Facultad de Ciencias de la Computación,
Quevedo, Ecuador

Resumen Contexto y motivación. Los modelos grandes de lenguaje se incorporan con rapidez a la elicitación de requisitos, pero la evidencia empírica sobre la calidad de los requisitos que producen sigue siendo escasa, y prácticamente inexistente en dominios agroindustriales y en contextos latinoamericanos.

Pregunta o problema. ¿Difiere la calidad de los requisitos funcionales elicitados por un equipo humano de la de los generados por un modelo grande de lenguaje a partir del mismo material fuente, y con qué grado de acuerdo la valoran personas evaluadoras que desconocen su procedencia?

Ideas principales. Se especifica un estudio comparativo con evaluación a ciegas sobre un caso real de ingeniería de requisitos en una unidad productiva de palma africana. Dos conjuntos de al menos veinticinco requisitos, uno humano y otro generado por el modelo desde una transcripción de entrevista anonimizada, se normalizan con identificadores neutros y se puntúan de uno a cinco en cinco dimensiones de calidad por tres personas evaluadoras independientes. El análisis trata las puntuaciones como ordinales y modela evaluador y requisito como factores aleatorios cruzados.

Contribución y limitaciones. La contribución de esta vista previa es el diseño y su prerregistro público, junto con una rúbrica operacionalizada de cinco dimensiones diseñada para ser adaptable a otros contextos. El estudio **aún no se ha ejecutado**: este manuscrito no presenta resultados. Las limitaciones conocidas son un único material fuente, un único modelo, personas evaluadoras del entorno académico y un tamaño muestral que sitúa la potencia por debajo del objetivo convencional.

Palabras clave Ingeniería de requisitos · Modelos grandes de lenguaje · Calidad de requisitos · Estudio prerregistrado · Evaluación a ciegas.

1. Introducción y motivación

La elicitación de requisitos incide de forma persistente en el resultado de los proyectos de software [15], y los atributos de calidad se definen de forma heterogénea entre estudios [16]. Sobre ese terreno se han incorporado con rapidez

los modelos grandes de lenguaje: la elicitación es una de las fases con menor evidencia acumulada [5], valorar la calidad del artefacto generado exige un procedimiento de evaluación controlado [2], y las prácticas de uso propuestas aún no han sido validadas de forma independiente [20].

Esta vista previa presenta el diseño de un estudio comparativo con evaluación a ciegas, prerregistrado antes de recoger puntuaciones, en un contexto poco representado: un proyecto de ingeniería de requisitos sobre una unidad productiva agroindustrial real en Ecuador.

2. Trabajo relacionado

La revisión que sustenta este diseño es **dirigida y de carácter narrativo**, no una revisión sistemática: no se conservó un registro auditable de consultas, y por tanto no se reclama exhaustividad ni reproducibilidad de la búsqueda.

Calidad de requisitos. La ISO/IEC/IEEE 29148:2018 fija los atributos exigibles a un requisito y a un conjunto [12] y es el marco normativo de este estudio; Pohl [19] y Wiegers y Beatty [21] los desarrollan en términos operativos. La dispersión de definiciones entre estudios [16] motiva que aquí se declare la operacionalización de cada dimensión (Sección 5). Ferrari et al. mostraron que la ambigüedad y el conocimiento tácito en entrevistas producen omisiones que el analista no detecta [8], hallazgo pertinente porque el material fuente de ambos conjuntos es una transcripción de entrevista. La línea sobre explicabilidad como requisito no funcional [4] enmarca los componentes de inteligencia artificial del sistema objeto del proyecto.

Contexto agroindustrial. La producción reciente sobre palma africana se concentra en el componente de percepción [18,14] y no aborda la especificación de requisitos del sistema que la incorpora, que es el hueco al que responde el proyecto en el que se inserta este estudio.

Método. El diseño sigue las guías de Wohlin et al. [23] y el reporte la plantilla de Jedlitschka et al. [13]. La práctica de prerregistro se apoya en Nosek et al. [17].

3. Contexto del estudio

El estudio se inserta en un proyecto de ingeniería de requisitos para un sistema de gestión del mantenimiento de un cultivo de palma africana, en una unidad productiva de unas cien hectáreas en la costa ecuatoriana, designada con un seudónimo por acuerdo de confidencialidad.

La especificación se elaboró conforme a la ISO/IEC/IEEE 29148:2018 [12], con los atributos de la ISO/IEC 25010:2023 [11] como marco de los requisitos no funcionales. El catálogo, sometido a inspección formal y a control de cambios, comprende **42 requisitos funcionales, 19 no funcionales, 10 restricciones de diseño y 8 requisitos legales**. La evidencia de campo procede de entrevistas semiestructuradas, un cuestionario al personal operativo, documentación

interna y observación directa, bajo consentimiento informado y seudonimizada conforme a la legislación ecuatoriana [3]. El experimento utiliza únicamente la transcripción anonimizada de una entrevista como material fuente común a los dos conjuntos.

4. Preguntas de investigación

Marco PICOC: **población**, requisitos funcionales de un sistema agroindustrial real; **intervención**, su generación mediante un modelo grande de lenguaje desde una transcripción anonimizada; **comparación**, los elicitados por el equipo humano desde el mismo material; **resultado**, la puntuación en cinco dimensiones de calidad; **contexto**, un proyecto académico de ingeniería de requisitos en Ecuador.

RQ1. ¿En qué dimensiones de calidad difieren los requisitos funcionales elicitados por un equipo humano de los generados por un modelo grande de lenguaje a partir del mismo material fuente?

RQ2. ¿Cuál es el grado de acuerdo entre personas evaluadoras independientes al valorar la calidad de requisitos funcionales sin conocer su procedencia?

Para cada dimensión d , la hipótesis nula sostiene que la distribución de puntuaciones no difiere entre conjuntos. El contraste es **bilateral**: la literatura reporta resultados mixtos y postular una dirección sin base constituiría un sesgo de expectativa.

5. Diseño del estudio

5.1. Variables

La **variable independiente** es el origen del requisito, nominal dicotómica. Las **variables dependientes** son cinco puntuaciones ordinales de 1 a 5, con descriptores por nivel y un ejemplo positivo y otro negativo en cada uno: *completitud* (presencia de los atributos de la plantilla), *ausencia de ambigüedad* (unicidad de interpretación), *verificabilidad* (existencia de un criterio objetivamente comprobable), *corrección* (fidelidad al contenido de la transcripción) y *consistencia interna* (ausencia de contradicción con el resto del conjunto). Se controlan el material fuente y la rúbrica, idénticos para ambos conjuntos; la ceguera de las personas evaluadoras respecto del origen; y el orden de presentación, aleatorizado con semilla registrada.

5.2. Materiales y participantes

Ambos conjuntos comprenden al menos veinticinco requisitos; el humano se extrae del catálogo seleccionando los trazados a la evidencia de la entrevista fuente. Se prevén tres personas evaluadoras independientes, estudiantes de otro paralelo de la misma asignatura sin participación en el proyecto. Se reportará el número efectivo, y ese número constituye una limitación del estudio.

5.3. Procedimiento

Verificada la anonimización de la transcripción fuente, el conjunto generado se obtiene con una consigna literal única, registrando modelo y versión, temperatura, *top-p*, *top-k*, semilla, fecha y hora, y la respuesta sin edición [20]. Ambos conjuntos se transcriben a una plantilla común con identificadores neutros, sin marca de procedencia, y se mezclan en orden aleatorio con semilla registrada; la correspondencia entre identificador y origen se conserva aparte y no se entrega a las evaluadoras. Cada una puntúa todos los requisitos de forma independiente. La procedencia se revela solo al completarse la recolección.

6. Plan de análisis

Alcance de este manuscrito. El plan que sigue describe análisis *previstos*: el experimento no se ha ejecutado y el documento no contiene puntuaciones, resultados ni discusión. Ninguna de las decisiones descritas en esta sección se ha tomado a la vista de datos observados. El registro público del protocolo tampoco equivale a un *Registered Report* con aceptación en fase 1, pues no hubo revisión previa del diseño por parte de una revista; se trata de una vista previa de investigación prerregistrada. El estado del estudio y los compromisos de reporte se detallan en la sección 8.

6.1. Desviación declarada respecto del prerregistro

El protocolo prerregistrado prevé contrastes **apareados** sobre unos veinticinco pares. Al revisar el diseño antes de recoger puntuación alguna se detectó que **no existe correspondencia uno a uno** entre cada requisito humano y uno generado: ambos conjuntos proceden del mismo material pero no describen necesariamente las mismas funciones, de modo que el emparejamiento carece de fundamento y el contraste apareado sería inválido.

Se declara por tanto la siguiente desviación, que se someterá como **adenda prospectiva al registro** *antes* de recoger ninguna puntuación:

1. Los conjuntos se tratan como **grupos independientes**, no apareados.
2. El análisis principal emplea un **modelo mixto de vínculo acumulativo** para respuesta ordinal [1], que respeta la naturaleza ordinal de la escala y la estructura de evaluaciones repetidas, que un contraste sobre medias no captura. Se ajustará **un modelo por cada una de las cinco dimensiones**, con la especificación $\text{puntuación}_{1-5} \sim \text{origen} + (1 \mid \text{evaluador}) + (1 \mid \text{requisito})$, donde el origen es efecto fijo y evaluador y requisito son interceptos aleatorios cruzados. Se empleará enlace logístico de probabilidades proporcionales, salvo que antes de ejecutar exista una razón metodológica preespecificada para otro enlace. La implementación prevista es el paquete **ordinal** de R, cuya versión exacta se registrará en el momento de la ejecución.

3. Si el modelo no converge, el análisis de reserva es la prueba **U de Mann–Whitney** sobre la mediana por requisito entre evaluadoras, con δ de Cliff [6] e intervalo de confianza al 95 % como tamaño del efecto.

Ninguna de estas decisiones se tomará en función de los datos observados.

6.2. Contrastes y acuerdo entre evaluadoras

Se contrastan cinco dimensiones sobre el mismo conjunto de datos; la corrección secuencial de Holm [10] se aplica a los **cinco contrastes del efecto de origen, uno por dimensión**, y se reportan los valores p crudos y corregidos, con $\alpha = 0,05$. Ninguna de estas decisiones se revisará tras observar las puntuaciones.

Para RQ2, el acuerdo se estima con el α **de Krippendorff con métrica ordinal** [9] como medida principal, y con κ **ponderado cuadrático** [7] por pares como medida secundaria. Se descarta el κ nominal de Cohen o de Fleiss previsto en el registro original: sobre una escala ordinal de 1 a 5 penaliza por igual un desacuerdo de un punto y uno de cuatro. Este cambio forma parte de la adenda descrita arriba.

6.3. Potencia

Como **aproximación de sensibilidad**, y no como potencia del modelo ordinal, se calculó la potencia de un contraste convencional de dos grupos independientes con $\alpha = 0,05$ bilateral y $d = 0,5$: veinticinco requisitos por grupo rinden aproximadamente **0,41**, y alcanzar 0,80 requeriría unos 64 por grupo. Una evaluación de potencia específica para el modelo mixto ordinal exigiría simulación, una vez preespecificadas las distribuciones y las componentes de varianza necesarias. La limitación se declara antes de ejecutar y no se corregirá ampliando la muestra a posteriori: la interpretación primará el tamaño del efecto con su intervalo de confianza sobre la significación estadística.

Todas las tablas y figuras del futuro reporte se producirán mediante *scripts* versionados; no se admitirán cifras calculadas manualmente.

7. Amenazas a la validez

Se identificaron antes de la ejecución, según las categorías de Wohlin et al. [23].

Constructo. La rúbrica puede no capturar la calidad de un requisito en su totalidad; las dimensiones proceden de la literatura [12,16] y la limitación se declara. La escala ordinal comprime juicios heterogéneos, lo que se mitiga con descriptores y ejemplos por nivel.

Interna. El conjunto humano lo elaboró el mismo equipo que ejecuta el estudio; se mitiga con evaluación a ciegas, identificadores neutros y orden aleatorizado con semilla registrada.

Externa. Un único material fuente, dominio y modelo; no se generalizará más allá del caso. Las evaluadoras son estudiantes y no profesionales: se declara el perfil real y no se atribuirá a su juicio la condición de experto.

Conclusión. La potencia queda por debajo de 0,80, por lo que se reporta el tamaño del efecto con intervalo de confianza y no solo el valor p . Un acuerdo bajo entre evaluadoras se reportará igualmente y se discutirá como hallazgo.

Amenazas del componente cualitativo que provee el material fuente. La transcripción que actúa como material fuente y el catálogo de requisitos del que se extrae el conjunto humano proceden de un estudio de campo previo, cuya interpretación se contrastó con las personas participantes mediante *member-checking*. Dos casos de ese proceso afectan a la confianza en dicho material y se declaran aquí; ambos constan en el registro de correcciones del proyecto (`correcciones_aplicadas.md`, casos D-02 y D-06).

Instrumento. Un enunciado de validación empleó el término *herramienta*, que una de las tres personas consultadas interpretó como herramienta física de trabajo y no como aplicación informática. El defecto es de formulación y no de la persona participante, y redujo de tres a dos las posiciones obtenibles sobre ese enunciado. Se reformuló el enunciado, se declara la pérdida de una posición y no se recabó de nuevo por encontrarse cerrado el trabajo de campo.

Credibilidad. Un segundo enunciado recibió posiciones incompatibles: dos personas confirmaron una carencia de detalle en los reportes que una tercera negó, sin que exista evidencia documental independiente que permita adjudicar entre ambas lecturas. La interpretación se conservó por contar con el respaldo de dos de tres fuentes y la divergencia se reporta sin conciliar, lo que limita la confianza en la parte del material derivada de ese enunciado.

8. Estado y contribución esperada

El protocolo está **diseñado y prerregistrado públicamente**, con marca temporal anterior a la ejecución del experimento y a la recolección de puntuaciones. El material fuente procede de trabajo de campo previo, ya existente en el momento del registro; el prerregistro no lo antecede ni lo pretende. **La ejecución está pendiente**, y por ello este manuscrito no contiene resultados ni discusión. Un registro público no equivale a un *Registered Report* con aceptación en fase 1: este trabajo es una vista previa de investigación prerregistrada, sin revisión previa del diseño.

El equipo se compromete a reportar el resultado con independencia de si confirma o refuta la hipótesis nula, a no modificar el plan según los datos observados y a declarar el número efectivo de evaluadoras y de requisitos. La contribución esperada es doble: evidencia empírica en un dominio agroindustrial poco representado, y una rúbrica operacionalizada de cinco dimensiones con sus descriptores.

Declaración de disponibilidad de datos

El prerregistro del protocolo está disponible en Open Science Framework (<https://osf.io/4z35d/>). El repositorio del proyecto, con la especificación de requisitos y la matriz de trazabilidad, es público (https://github.com/AlanNVR/SIMPA_ISR401).

Como material de apoyo se ha depositado un conjunto con estadística descriptiva agregada del cuestionario aplicado al personal operativo (10.5281/zenodo.22236500). **Ese depósito no contiene los datos del experimento aquí descrito**, que todavía no se ha ejecutado.

Se publicarán **cuando se ejecute el estudio**: la consigna literal y los parámetros de generación, los dos conjuntos normalizados, la rúbrica completa con sus descriptores y los *scripts* de análisis. A la fecha de este manuscrito el repositorio contiene la plantilla de registro de consignas, sin ejecuciones registradas, y los instrumentos de forma parcial. El *commit* de ejecución se fijará y declarará en su momento; ninguna etiqueta actual identifica una versión evaluada del experimento.

Las puntuaciones individuales de cada evaluadora **solo se publicarán si su consentimiento específico autoriza ese nivel de detalle**; en caso contrario, solo datos agregados que no permitan atribuir juicios a personas concretas. El diseño de publicación sigue los principios FAIR [22].

Uso de tecnologías asistidas por inteligencia artificial

Como objeto de estudio. La generación de uno de los conjuntos mediante un modelo grande de lenguaje es la intervención experimental; el modelo y su versión, los parámetros, la consigna literal y la respuesta sin editar se registrarán y publicarán.

Como apoyo a la redacción. Las personas autoras emplearon el asistente Claude (Anthropic) en la redacción y reestructuración de este manuscrito, en la revisión de coherencia interna del texto y en la elaboración de un borrador de la lista de referencias, incluida la sugerencia de obras metodológicas canónicas. **Antes del envío, las referencias citadas serán contrastadas contra sus fuentes bibliográficas o editoriales originales y sus identificadores persistentes cuando estén disponibles.** El asistente no se empleó para generar resultados ni para redactar interpretaciones de datos, que no existen. La responsabilidad sobre el contenido, las decisiones metodológicas y las afirmaciones sostenidas es íntegramente de las personas autoras.

Agradecimientos y conflicto de intereses

Las personas autoras agradecen a la unidad productiva participante y a su personal el tiempo dedicado a las entrevistas y el acceso a la documentación operativa. Una de las personas autoras mantiene una relación de parentesco con el representante de la organización participante; la circunstancia se declaró ante

la instancia académica antes del trabajo de campo y se adoptaron medidas de mitigación documentadas. No se declaran otros conflictos de intereses.

Referencias

1. Agresti, A.: Analysis of Ordinal Categorical Data. Wiley, 2 edn. (2010). <https://doi.org/10.1002/9780470594001>
2. Arora, C., Grundy, J., Abdelrazek, M.: Advancing requirements engineering through generative AI: Assessing the role of LLMs. In: Nguyen-Duc, A., Abrahamson, P., Khomh, F. (eds.) Generative AI for Effective Software Development, pp. 129–148. Springer, Cham, Switzerland (2024). https://doi.org/10.1007/978-3-031-55642-5_6
3. Asamblea Nacional del Ecuador: Ley orgánica de protección de datos personales. Registro Oficial, Quinto Suplemento N. 459, 26 de mayo de 2021 (2021), <https://www.registroficial.gob.ec/quinto-suplemento-al-registro-oficial-no-459/>
4. Chazette, L., Brunotte, W., Speith, T.: Exploring explainability: A definition, a model, and a knowledge catalogue. In: Proceedings of the 29th IEEE International Requirements Engineering Conference (RE'21). pp. 197–208. IEEE (2021). <https://doi.org/10.1109/RE51729.2021.00025>
5. Cheng, H., Husen, J.H., Lu, Y., Racharak, T., Yoshioka, N., Ubayashi, N., Washizaki, H.: Generative AI for requirements engineering: A systematic literature review. Software: Practice and Experience **56**(2), 141–170 (2026). <https://doi.org/10.1002/spe.70029>
6. Cliff, N.: Dominance statistics: Ordinal analyses to answer ordinal questions. Psychological Bulletin **114**(3), 494–509 (1993). <https://doi.org/10.1037/0033-2909.114.3.494>
7. Cohen, J.: Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. Psychological Bulletin **70**(4), 213–220 (1968). <https://doi.org/10.1037/h0026256>
8. Ferrari, A., Spoletini, P., Gnesi, S.: Ambiguity and tacit knowledge in requirements elicitation interviews. Requirements Engineering **21**(3), 333–355 (2016). <https://doi.org/10.1007/s00766-016-0249-3>
9. Hayes, A.F., Krippendorff, K.: Answering the call for a standard reliability measure for coding data. Communication Methods and Measures **1**(1), 77–89 (2007). <https://doi.org/10.1080/19312450709336664>
10. Holm, S.: A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics **6**(2), 65–70 (1979). <https://doi.org/10.2307/4615733>
11. ISO/IEC: ISO/IEC 25010:2023 — systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — product quality model. Tech. rep., International Organization for Standardization / International Electrotechnical Commission, Geneva, Switzerland (2023), <https://www.iso.org/standard/78176.html>
12. ISO/IEC/IEEE: ISO/IEC/IEEE 29148:2018 — systems and software engineering — life cycle processes — requirements engineering. Tech. rep., International Organization for Standardization / International Electrotechnical Commission / Institute of Electrical and Electronics Engineers, Geneva, Switzerland (2018). <https://doi.org/10.1109/IEEESTD.2018.8559686>

13. Jedlitschka, A., Ciolkowski, M., Pfahl, D.: Reporting experiments in software engineering. In: Shull, F., Singer, J., Sjøberg, D.I.K. (eds.) *Guide to Advanced Empirical Software Engineering*, pp. 201–228. Springer London, London (2008). https://doi.org/10.1007/978-1-84800-044-5_8
14. Kipli, K., Osman, S., Joseph, A., Zen, H., Awang Salleh, D.N.S.D., Lit, A., Chin, K.L.: Deep learning applications for oil palm tree detection and counting. *Smart Agricultural Technology* **5**, 100241 (2023). <https://doi.org/10.1016/j.atech.2023.100241>
15. Méndez Fernández, D., Wagner, S., Kalinowski, M., Felderer, M., Mafra, P., Vetrò, A., Conte, T., et al.: Naming the pain in requirements engineering: contemporary problems, causes, and effects in practice. *Empirical Software Engineering* **22**(5), 2298–2338 (2017). <https://doi.org/10.1007/s10664-016-9451-7>
16. Montgomery, L., Fucci, D., Bouraffa, A., Scholz, L., Maalej, W.: Empirical research on requirements quality: a systematic mapping study. *Requirements Engineering* **27**(2), 183–209 (2022). <https://doi.org/10.1007/s00766-021-00367-z>
17. Nosek, B.A., Ebersole, C.R., DeHaven, A.C., Mellor, D.T.: The preregistration revolution. *Proceedings of the National Academy of Sciences* **115**(11), 2600–2606 (2018). <https://doi.org/10.1073/pnas.1708274114>
18. Omar, Z., Abdul Majeed, A.P.P., Rosbi, M., Ghazalli, S.A., Selamat, H.: Outdoor oil palm fruit ripeness dataset. *Data in Brief* **55**, 110667 (2024). <https://doi.org/10.1016/j.dib.2024.110667>
19. Pohl, K.: *Requirements Engineering: Fundamentals, Principles, and Techniques*. Springer, Berlin, Heidelberg (2010). <https://doi.org/10.1007/978-3-642-12578-2>
20. Vogelsang, A., Fischbach, J.: Using large language models for natural language processing tasks in requirements engineering: A systematic guideline. In: Ferrari, A., Ginde, G. (eds.) *Handbook on Natural Language Processing for Requirements Engineering*, pp. 435–456. Springer, Cham (2025). https://doi.org/10.1007/978-3-031-73143-3_16
21. Wiegers, K.E., Beatty, J.: *Software Requirements*. Microsoft Press, 3 edn. (2013)
22. Wilkinson, M.D., Dumontier, M., Aalbersberg, I.J., Appleton, G., Axton, M., Baak, A., et al.: The FAIR guiding principles for scientific data management and stewardship. *Scientific Data* **3**, 160018 (2016). <https://doi.org/10.1038/sdata.2016.18>
23. Wohlin, C., Runeson, P., Höst, M., Ohlsson, M.C., Regnell, B., Wesslén, A.: *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg (2012). <https://doi.org/10.1007/978-3-642-29044-2>